

Priorización de clientes para depósitos a plazo

¿A quién llamar primero en una campaña de telemarketing bancario?

Ricardo Victor Ambrocio Tantalean (U202315214)

Aaron Alvaro Felices Vallejos (U202315164)

Docente: Carlos Fernando Montoya Cubas

Casi 9 de cada 10 llamadas no terminan en venta

11.7%

de los contactos suscribe el
depósito a plazo

Llamar a todos por igual gasta tiempo de
agentes y cansa al cliente.

Pregunta del proyecto

Con la información disponible antes de llamar, ¿se puede ordenar a los clientes de modo que llamando solo al 20% con mayor puntaje se alcance al menos a la mitad de los que suscribirían?

Criterios de éxito, fijados antes de modelar

- 1 Captar $\geq 50\%$ de los suscriptores llamando al 20% de la lista (lift ≥ 2.5)
- 2 Superar a una regla de negocio simple, no solo al azar
- 3 No usar información que se conozca después de la llamada

El dataset: contactos reales de un banco portugués

45,211

contactos de campaña

16

variables de entrada: perfil,
finanzas e historial

2008-2010

ordenado por fecha, sin año
explícito

CC BY 4.0

UCI Bank Marketing, id 222
(Moro et al., 2014)


Por qué es adecuado

- Mezcla variables numéricas y categóricas
- Tiene desbalance, faltantes y códigos centinela reales
- Obliga a decidir qué se puede usar antes de llamar

Limitaciones conocidas

- Un solo banco, en plena crisis financiera
- Solo clientes que el banco decidió llamar
- Sin identificador de cliente ni variables macroeconómicas

El perfil y el historial separan a quienes suscriben



63.8%

vuelve a aceptar si aceptó en la campaña anterior (solo 3.3% de los contactos)

28.7%



de los estudiantes y 22.7% de los jubilados suscriben

41.9%

en mayores de 60: la edad tiene forma de U

Tasa de suscripción en train. Línea punteada: tasa global (11.7%).

Los datos cambian en el tiempo: de 3% a 47% de suscripción





Lo que muestran los datos

Mayo: 8,259 contactos y 6.8% de éxito. Marzo, septiembre, octubre y diciembre: pocos contactos y 43-49%.

Nuestra interpretación

El mes parece identificar el tipo de campaña, no una estacionalidad estable. Un split aleatorio puede dar una imagen optimista.

duration predice bien, pero se conoce después de llamar



Llamadas de hasta 89 s: 0.6% de éxito. Más de 367 s: 33.4%. La llamada es larga porque el cliente ya está aceptando.

Cuánto inflaría las métricas

0.80

ROC-AUC sin duration (modelo del proyecto)


0.94

ROC-AUC con duration: cifra que no se puede obtener antes de llamar

Decisión: duration se excluye del modelo

Usarla sería data leakage: métricas excelentes en el notebook y un modelo inútil para decidir a quién llamar.

Un solo pipeline, ajustado únicamente con train



Separación

- Train 60%: ajuste y validación cruzada (5 particiones)
- Validation 20%: comparar modelos y fijar el umbral
- Test 20%: sin usar hasta el TF1


Preparación

- Faltantes como categoría unknown: son informativos
- pdays = -1 es un código, no una cantidad de días
- Logaritmo para extremos; no se eliminó ninguna fila

Contra el leakage

- duration fuera del modelo
- Split antes del EDA con la variable objetivo
- Escalado y one-hot dentro del Pipeline

En validación, el modelo capta 63% llamando al 20% de la lista



Criterio de éxito: 50%. Conjunto de validación (9,042 contactos).

3.2x


mejor que llamar al azar

1.7x

mejor que la regla de negocio

Random Forest y boosting están empatados. Boosting queda como modelo preliminar por razones prácticas, no porque sea mejor.

Entrenando con el pasado, la ventaja casi desaparece



Prueba temporal: entrenar con el 80% más antiguo y evaluar en el 20% más reciente.

34.0%

de captura del modelo preliminar: no llega al 50% y supera a la regla por solo 1.6 puntos

Por qué creemos que ocurre

La tasa de suscripción pasa de 6.8% en el tramo antiguo a 31.3% en el reciente. El modelo aprendió de campañas masivas que no se parecen a las últimas. Es una hipótesis.

Qué queda abierto y qué haremos para el Trabajo Final

Problemas no resueltos

- No sabemos cuánto rinde el modelo en una campaña nueva
- Random Forest y boosting siguen empatados
- Puntajes sin calibrar; umbral basado en un supuesto
- month y contact = unknown marcan el periodo

Lo que no se puede concluir

El modelo describe asociaciones, no causas, y no hay base para generalizar a otro banco o época.

Plan hacia el TF1

- 1 Validación temporal como esquema principal**
TimeSeriesSplit
- 2 Ajuste de hiperparámetros y registro de experimentos**
Optuna + MLflow
- 3 Calibración y umbral con escenarios de costo**
CalibratedClassifierCV
- 4 Interpretabilidad y análisis de errores**
SHAP
- 5 Segmentación de clientes**
K-Means + PCA / UMAP
- 6 Evaluación final única sobre test**
Test sigue sin usarse

Qué nos llevamos del Trabajo Parcial

Sí se puede ordenar

Dentro de un mismo periodo, el modelo capta 63% de los suscriptores llamando al 20%.

Sin atajos

duration queda fuera: el modelo usa solo lo que se sabe antes de llamar.

Con un límite claro

Entre periodos la ventaja cae a 34%. Resolverlo es el objetivo del TF1.

Repositorio: github.com/Ravit18/data-mining-tools-tp

Aplicación: data-mining-tools-tp.streamlit.app

Gracias. ¿Preguntas?